



El objetivo del trabajo es preparar un ejercicio que integre dos fuentes de datos en una organización e implementar la capa de persistencia de un repositorio de metadatos.

Fuentes de datos:

classicmodels – Base de datos MySQL que contiene los datos de órdenes de compra organizadas en maestro y detalle. Se guardan los datos de los clientes, productos, representantes de ventas, órdenes de compra y pagos.

El archivo para restaurar la base de datos lo puede encontrar en “BrigthSpace/Proyecto Final” bajo el nombre de “mysqlsampledatabse.sql”

customerservice – Base de datos PostgreSQL que contiene el registro de las llamadas al call center de la compañía y relaciona las llamadas con un empleado que recibe la llamada, así como a los clientes y los productos sobre los que se hacen las llamadas.

El archivo para restaurar la base de datos lo puede encontrar en “BrigthSpace /Proyecto Final” bajo el nombre de “customerservice.sql”

Tareas que usted debe realizar:

1. *Descubrimiento:* Documentar los metadatos de las fuentes de información. Se debe analizar la estructura de las fuentes de datos y las reglas de negocio que se encuentran en los metadatos. Se deben identificar estructuras en común entre las 2 fuentes de datos y sus diferencias.
2. *Perfilamiento:* Documentar el análisis de los datos de las fuentes de información enfocándose en la calidad de los datos y la posibilidad de integrar las 2 fuentes de datos. Se debe analizar por cada columna:
 - Rangos de los datos (máximos y mínimos) para datos numéricos y fechas
 - Patrones de strings para datos tipo texto
 - % de datos nulos
 - Para las estructuras en común se debe identificar si hay correspondencia o no entre los datos y si hay datos duplicados entre las 2 fuentes.
3. *Repositorio de metadatos:* Diseñar e implementar la base de datos de un repositorio de metadatos, en la cual se integren los **metadatos técnicos** de las 2 fuentes de datos. La integración de metadatos técnicos se debe hacer mediante procesos automáticos (e.g. ETLs) que consulten el diccionario de datos de las fuentes, y lleven los metadatos al repositorio.
En el repositorio también se deben registrar los **metadatos de negocio** (se pueden ingresar manualmente) que permitan describir las principales entidades de negocio y sus atributos. Una característica importante del repositorio de metadatos es que debe permitir hacer



análisis de linaje semántico, lo que se traduce en conectar los metadatos técnicos y de negocio.

Una vez se tengan los metadatos consolidados en el repositorio se deben poder contestar las siguientes preguntas mediante consultas a la base de datos de metadatos:

- ¿Cuáles tablas se tienen en las fuentes de datos y en qué base de datos está cada tabla?
- Para una tabla específica. ¿Qué columnas tiene? (Se debe mostrar el nombre de la columna, tipo de dato y si es parte de la llave primaria)
- Glosario de negocio: ¿Qué entidades de negocio existen en la organización, cual es la descripción de cada una y su dominio de datos?
- Para una entidad específica. ¿Qué atributos tiene? (Mostrar nombre del atributo y definición)
- Reporte de ubicación de entidades: Mostrar todas las entidades de negocio, junto con la(s) tabla(s) que almacenan la información relacionada con esa entidad (nombre de bd y nombre de tabla).
- Linaje semántico de columnas: Para la tabla `cs_customers`, mostrar por cada columna: nombre de columna, tipo de dato, nombre de atributo de negocio correspondiente, definición de atributo y nombre de entidad de negocio.

Entregables:

- **Documento describiendo**
 - o Metadatos de las fuentes (Descubrimiento) [25%]
 - Utilice tablas para definir los metadatos y poner su significado
 - No olvide especificar metadatos de negocio, técnicos y de linaje
 - o Resultado del perfilamiento [25%]
 - No olvide analizar cada uno de los elementos de calidad descritos previamente.
 - Puede agregar otros si lo desea
 - o Diseño Físico de Repositorio de Metadatos [26%]
 - Debe incluir un diagrama físico que muestre su diseño de la base de datos de metadatos
 - o Consultas [24%]
 - Mostrar cómo se hizo la consulta y el resultado de la consulta
- **Archivo backup de la base de datos**
 - o Debe tener todos los metadatos llenos
 - o Especifique que BD utilizó MySQL, Oracle, PostgreSQL etc.



- **Archivo ETL del proceso de metadatos técnicos**
 - Se recomienda usar Python pero queda a libertad del grupo la herramienta a usar.
 - Especifique qué herramienta utilizo para crearlo.

Recomendaciones para la carga de los datos:

- Recomendando usar <https://railway.app> como servicio cloud de fácil acceso, sin embargo tiene un costo de 5 dólares mensuales.
- Para Base de datos on premise mysql, puede instalar MySQL Workbench
- Puede descargarlo en este link: <https://dev.mysql.com/downloads/workbench/>
- Si desea consultar los prerequisites puede ver este link: <https://dev.mysql.com/doc/workbench/en/wb-requirements.html>
- Para base de datos postgresql on premise, puede instalar PostgreSQL
- Puede descargarlo de este link: <https://www.enterprisedb.com/downloads/postgres-postgresql-downloads>
- Algunas herramientas de perfilamiento deben ser actualizadas manualmente para instalar el plugin que permita la conexión a algunos motores de bases de datos. Leer atentamente la documentación y foros para asegurar un correcto funcionamiento.